

Deteksi Dini Deforestasi di Hutan Lindung Menggunakan U-Net dan Citra Sentinel-2

Idea Concept Paper — Deforest.id

Tim Riset — Deforest.id

Abstrak. Kami mengusulkan sistem peringatan deforestasi otomatis untuk hutan lindung Indonesia menggunakan model deep learning U-Net pada citra Sentinel-2 resolusi 10 m. Inovasi utamanya adalah pipeline yang sepenuhnya otonom: label pelatihan dihasilkan melalui NDVI temporal differencing, menghilangkan kebutuhan anotasi manual. Kerangka kerja peringatan dini tiga tingkat (Waspada/Siaga/Kritis) dengan amplifikasi peringatan untuk kawasan lindung langsung terpetakan ke standar pelaporan nasional dan internasional. Hasil awal menunjukkan IoU 0,73 dan Dice 0,84 pada data uji terpisah, dengan deteksi andal pada 0,64 ha per tile. Sistem ini dirancang untuk penyebaran cepat di 94 juta hektar kawasan hutan Indonesia tanpa survei lapangan, mendukung target FOLU Net Sink 2030.

1 Latar Belakang

Indonesia memiliki hutan tropis terbesar ketiga di dunia 94 juta ha, namun kehilangan 300 ribu ha hutan alam setiap tahunnya [1]. Hutan lindung yang mengatur daerah aliran sungai, mencegah erosi, dan menjaga kesuburan tanah bagi jutaan orang – sangat rentan terhadap deforestasi skala kecil yang luput dari sistem monitoring resolusi kasar. Dampak kumulatifnya parah: petak lebih kecil dari 2 ha menyumbang lebih dari 56% emisi karbon hutan tropis [2], sementara fragmentasi mempercepat hilangnya keanekaragaman hayati [3].

Kesenjangan. Sistem operasional saat ini tidak dapat menjembatani kesenjangan skala ini. Global Forest Watch beroperasi pada resolusi 30 m (Landsat), melewatkan pembukaan lahan di bawah 0,9 ha. Sistem SIMONTANA Indonesia menggunakan unit pemetaan minimum 6,25 ha untuk pelaporan REDD+ [4] tiga kali lipat ambang batas 2 ha di mana dampak ekologis menjadi parah. Lebih krusial lagi, tidak ada sistem yang menyediakan *prioritasi peringatan otomatis* untuk kawasan lindung, yang secara hukum memerlukan pengawasan lebih ketat berdasarkan UU No. 41/1999. Program NICFI Norwegia menyediakan citra resolusi tinggi tetapi hanya pada interval bulanan dan tanpa analisis otomatis. Inti masalahnya adalah kesenjangan resolusi monitoring: deforestasi pada skala 0,5–2 ha terlalu kecil untuk sensor kasar dan terlalu besar untuk diabaikan secara ekologis [5, 6].

2 Metode

Paper ini dikategorikan sebagai penelitian kuantitatif yang berfokus pada pengembangan model komputasi atau teknis (*computational/technical research*). Kategori ini dipilih karena analisis utama penelitian bertumpu pada data numerik dari citra satelit, seperti nilai piksel, indeks spektral NDVI, dan luas area deforestasi dalam hektar. Dengan demikian, proses pengambilan keputusan dalam sistem ini tidak didasarkan pada observasi kualitatif atau wawancara, melainkan pada pengukuran kuantitatif yang dapat dihitung, dibandingkan, dan divalidasi secara sistematis [7, 8].

Penelitian ini menggunakan 7 scene Sentinel-2 L1C dari Riau dan Kalimantan Tengah (2019–2024) yang menghasilkan 60.587 tile 64×64 (50% overlap): 40.484 baseline dan 20.103 deforestasi, dibagi menjadi 11.500 latih, 2.908 validasi, dan 5.695 uji. Dari sisi evaluasi, keberhasilan model diukur menggunakan metrik statistik kuantitatif yang jelas, yaitu Intersection over Union (IoU), Dice coefficient, precision, dan recall. Metrik-metrik ini digunakan untuk menilai kesesuaian antara mask deforestasi hasil prediksi dan mask acuan pada data uji. Pengujian dilakukan pada data *hold-out*, yaitu data yang tidak digunakan selama pelatihan, sehingga performa model dapat dievaluasi secara lebih objektif terhadap scene yang belum pernah dilihat sebelumnya [9, 10].

Dalam konteks riset teknologi, penelitian ini juga dapat dipahami sebagai *design science research* atau penelitian pengembangan (*developmental research*). Fokus utamanya adalah membangun, menguji, dan mengevaluasi efektivitas sebuah artefak teknis, yaitu sistem deteksi deforestasi berbasis U-Net, untuk menyelesaikan masalah spesifik berupa kesenjangan resolusi dalam pemantauan deforestasi. Artefak tersebut dirancang sebagai pipeline komputasi yang mencakup akuisisi citra, pseudo-labeling, pelatihan model, inferensi, dan klasifikasi

peringatan berbasis luas area [11, 12].

3 Deskripsi Riset

Kami menyajikan pipeline ujung-ke-ujung yang menggabungkan citra multi-spektral Sentinel-2 (10 m, revisit 5 hari, akses terbuka) dengan arsitektur deep learning U-Net. Pipeline ini sepenuhnya otonom: menghasilkan data pelatihannya sendiri, mendeteksi awan tanpa bergantung pada band QA60 yang rusak, dan mengeluarkan peringatan keparahan berbasis area yang langsung terpetakan ke ambang kebijakan [13].

3.1 Pelatihan Otonom melalui Pseudo-Labeling

Inovasi teknis inti adalah metode NDVI temporal differencing yang menghasilkan label pelatihan berkualitas tinggi tanpa anotasi manual. NDVI dihitung dari kanal merah (Red) dan inframerah dekat (NIR) [7]:

$$\text{NDVI} = \frac{\text{NIR} - \text{Red}}{\text{NIR} + \text{Red}} \quad (1)$$

Untuk setiap pasangan temporal, kami menghitung selisih NDVI:

$$\Delta\text{NDVI}(x, y) = \text{NDVI}_{\text{sebelum}} - \text{NDVI}_{\text{sesudah}} \quad (2)$$

dan melakukan thresholding untuk menghasilkan mask deforestasi biner:

$$\text{mask}(x, y) = \begin{cases} 1 & \Delta\text{NDVI} < -0,15 \\ 0 & \text{lainnya} \end{cases} \quad (3)$$

Penutupan morfologis (kernel 3×3) menghilangkan derau salt-and-pepper. Pendekatan ini memanfaatkan fakta bahwa deforestasi menyebabkan penurunan NDVI yang tajam dan berkelanjutan, berbeda dari variasi musiman (yang cenderung bertahap dan dua arah). Ambang batas $-0,15$ dipilih karena berada dalam rentang threshold yang umum digunakan untuk deteksi perubahan vegetasi [14] dan dikalibrasi terhadap interpretasi visual dari 50 sampel acak di 3 scene. Pseudo-labeling ini memungkinkan skalabilitas: model yang dilatih di satu wilayah dapat di-fine-tune untuk wilayah lain tanpa kampanye lapangan yang mahal [15].

3.2 Kerangka Peringatan Dini

Setiap piksel Sentinel-2 mewakili $10 \times 10 \text{ m} = 0,01 \text{ ha}$, memungkinkan konversi area langsung: $A(\text{ha}) = N_{\text{piksel}} \times 0,01$. Area deforestasi terdeteksi diklasifikasikan ke dalam tiga tingkat keparahan (Tabel 1), dengan peringatan secara otomatis dinaikkan satu tingkat untuk kawasan hutan lindung [16].

Tabel 1: Ambang batas peringatan yang mensintesis standar FAO, ekologis, dan nasional.

Tingkat	Area (ha)	Piksel
<i>Waspada</i>	$\geq 0,64$	≥ 64
<i>Siaga</i>	$\geq 2,00$	≥ 200
<i>Kritis</i>	$\geq 6,25$	≥ 625

Baseline 0,64 ha sejajar dengan definisi minimum hutan FAO (0,5 ha) [17], 2 ha dengan ambang fragmentasi ekologis [18], dan 6,25 ha dengan minimum REDD+ Indonesia [19]. Untuk hutan lindung, amplifikasi berbasis area diterapkan: *Siaga* meningkat menjadi *Kritis*, *Waspada* meningkat menjadi *Siaga*. Ini memastikan kawasan lindung menerima respons penegakan hukum yang lebih cepat sesuai dengan status perlindungan hukumnya [20].

3.3 Deteksi Awan Tanpa QA60

Band QA60 Sentinel-2 mentah dari GEE hanya berisi nol placeholder. Kami menerapkan heuristik sederhana namun efektif [21]:

$$\text{awan}(x, y) = R > 180 \wedge G > 180 \wedge B > 180 \wedge \text{NDVI} < 0,10$$

Ini menangkap awan kumulus tebal; sisa awan tipis dan bayangan ditangani oleh ketahanan Dice loss terhadap noise label selama pelatihan [10].

3.4 Pipeline Implementasi

Pipeline beroperasi dalam enam tahap [22, 23]:

1. **Akuisisi:** 7 scene Sentinel-2 (L1C) dari Riau dan Kalimantan Tengah (2019–2024), diunduh melalui Google Earth Engine.
2. **Tiling:** Scene dibagi menjadi blok 512×512 , lalu tile 64×64 dengan overlap 50% mengikuti strategi overlap-tile [11], menghasilkan 40.484 tile baseline dan 20.103 tile deforestasi.
3. **Cloud masking:** Filter heuristik diterapkan per tile; tile yang terkontaminasi awan ditandai untuk dikecualikan.
4. **Pseudo-labeling:** $\Delta\text{NDVI} < -0,15$ dengan penutupan morfologis (3×3) menghasilkan mask.
5. **Pelatihan:** U-Net (4 tahap encoder/decoder, 32–512 filter, input 5 kanal), Dice loss, Adam (1×10^{-4}), batch 64, 50 epoch, split 11.500/2.908/5.695. Band NIR dinormalisasi ke $[0, 1]$ melalui pembagian dengan 10.000.
6. **Inferensi:** Sliding window (overlap 50%), connected-component labeling, agregasi area, klasifikasi peringatan per ambang batas.

4 Hasil Awal, Dampak, dan Skalabilitas

Pelatihan pada satu RTX 3060 (12 GB) membutuhkan $\sim 2,7$ menit/epoch; 50 epoch selesai dalam < 3 jam dengan `num_workers=0` untuk kompatibilitas WSL. Pada 5.695 tile uji dari 2 scene yang tidak dilihat sebelumnya [9]:

- **IoU:** 0,7256
- **Dice:** 0,8410
- **Presisi:** 0,8340
- **Recall:** 0,8480

Sistem ini andal mendeteksi petak deforestasi pada 64 piksel (0,64 ha), yang merupakan ambang peringatan minimum kami. Sebagai perbandingan, ambang temporal NDVI sederhana ($\Delta\text{NDVI} < -0,15$) hanya mencapai $\sim 0,53$ F1 pada set uji yang sama, mengonfirmasi bahwa U-Net mempelajari konteks spasial di luar perubahan spektral [24].

Dampak dan Skalabilitas. Sistem yang diusulkan akan memberikan Kementerian Lingkungan Hidup dan Kehutanan peringatan deforestasi harian otomatis pada resolusi efektif 0,01 ha – peningkatan 900 kali lipat dari minimum REDD+ 6,25 ha. Tiga fitur memastikan viabilitas praktis [25]:

Biaya anotasi nol. Pipeline pseudo-labeling menghasilkan label pelatihan dari pasangan citra Sentinel-2 mana pun, memungkinkan penskalaan ke semua 38 provinsi Indonesia tanpa survei lapangan. Perkiraan biaya pembuatan label per provinsi: ~ 30 menit komputasi cloud untuk pemrosesan pasangan citra [12].

Kelayakan perangkat keras konsumen. Pelatihan selesai dalam waktu kurang dari 3 jam pada satu GPU konsumen (RTX 3060, $\sim \$250$). Inferensi pada satu scene Sentinel-2 penuh membutuhkan < 5 menit. Ini menghilangkan ketergantungan pada cloud compute atau infrastruktur khusus, membuat sistem dapat diakses oleh dinas kehutanan provinsi [26].

Keselarasan kebijakan. Ambang peringatan langsung terpetakan ke pelaporan REDD+ nasional (6,25 ha), definisi hutan FAO (0,5 ha), dan ambang ekologis 2 ha. Amplifikasi kawasan lindung tidak memerlukan perubahan legislatif – ini mengoperasionalkan perlindungan hukum yang ada berdasarkan UU No. 41/1999. Sistem ini secara langsung mendukung target FOLU Net Sink 2030 dengan memungkinkan intervensi penegakan hukum yang lebih awal [27].

5 Kesimpulan

Paper ini menunjukkan bahwa deteksi dini deforestasi di hutan lindung Indonesia dapat dilakukan secara kuantitatif melalui kombinasi citra Sentinel-2 dan U-Net. Pipeline otonom yang diusulkan menggabungkan pseudo-labeling berbasis perubahan NDVI, segmentasi citra, cloud masking, dan klasifikasi peringatan berbasis luas area. Hasil awal pada data uji terpisah menunjukkan performa menjanjikan dengan IoU 0,7256, Dice 0,8410, precision 0,8340, dan recall 0,8480. Dengan ambang 0,64 ha, 2 ha, dan 6,25 ha, sistem ini berpotensi menjadi dasar teknis pemantauan deforestasi dini yang lebih cepat, murah, dan selaras dengan kebutuhan pelaporan serta target FOLU Net Sink 2030.

Daftar Pustaka

- [1] FAO, *The State of the World's Forests 2022*. Rome: Food and Agriculture Organization of the United Nations, 2022.
- [2] D. Wahyuni *et al.*, “Dampak fragmentasi hutan terhadap emisi karbon di indonesia,” 2021. In Indonesian.
- [3] F. Taubert, R. Fischer, J. Groeneveld, *et al.*, “Global patterns of tropical forest fragmentation,” *Nature*, vol. 554, pp. 519–522, 2018.
- [4] UNFCCC, “Indonesia’s national forest reference emission level for deforestation and forest degradation,” 2022. REDD+ submission to UNFCCC.
- [5] M. C. Hansen, P. V. Potapov, R. Moore, *et al.*, “High-resolution global maps of 21st-century forest cover change,” *Science*, vol. 342, no. 6160, pp. 850–853, 2013.
- [6] Norway’s International Climate and Forest Initiative, “Nici satellite data program — high-resolution imagery for tropical forest monitoring,” 2020. Planet Labs and KSAT. Accessed via Google Earth Engine.
- [7] C. J. Tucker, “Red and photographic infrared linear combinations for monitoring vegetation,” *Remote Sensing of Environment*, vol. 8, no. 2, pp. 127–150, 1979.
- [8] R. G. Congalton, “A review of assessing the accuracy of classifications of remotely sensed data,” *Remote Sensing of Environment*, vol. 37, no. 1, pp. 35–46, 1991.
- [9] D. M. W. Powers, “Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation,” *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.
- [10] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” *International Conference on 3D Vision (3DV)*, pp. 565–571, 2016.
- [11] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, vol. 9351, pp. 234–241, 2015.
- [12] N. Gorelick, M. Hancher, M. Dixon, *et al.*, “Google earth engine: Planetary-scale geospatial analysis for everyone,” *Remote Sensing of Environment*, vol. 202, pp. 18–27, 2017.
- [13] M. Drusch, U. Del Bello, S. Carlier, *et al.*, “Sentinel-2: ESA’s optical high-resolution mission for GMES operational services,” *Remote Sensing of Environment*, vol. 120, pp. 25–36, 2012.
- [14] G. M. Gandhi, S. Parthiban, N. Thummalu, and A. Christy, “Ndvi: Vegetation change detection using remote sensing and GIS – A case study of Vellore District,” *Procedia Computer Science*, vol. 57, pp. 1199–1210, 2015.
- [15] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*. Pearson Prentice Hall, 3rd ed., 2008.
- [16] European Space Agency, “Sentinel-2 user handbook,” 2024. ESA Standard Document.
- [17] FAO, “Global forest resources assessment 2020: Terms and definitions,” Tech. Rep. FRA Working Paper 188, Food and Agriculture Organization of the United Nations, 2018.
- [18] C. D. Renno, A. D. Nobre, *et al.*, “Amazon forest fragmentation and its effects on ecosystem function,” *Nature Climate Change*, 2016. Threshold analysis of 2 ha fragmentation impacts.
- [19] Global Forest Watch, “Global forest watch’s 2024 tree cover loss data explained,” July 2025. Blog post detailing SIMONTANA minimum mapping unit of 6.25 ha.
- [20] Republik Indonesia, “Undang-undang no. 41 tahun 1999 tentang kehutanan,” 1999.
- [21] Z. Zhu and C. E. Woodcock, “Object-based cloud and cloud shadow detection in landsat imagery,” *Remote Sensing of Environment*, vol. 118, pp. 83–94, 2012.
- [22] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” *International Conference on Learning Representations (ICLR)*, 2015.
- [23] L. G. Shapiro and G. C. Stockman, *Computer Vision*. Prentice Hall, 2001.
- [24] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [25] Ministry of Environment and Forestry, “Indonesia’s folu net sink 2030: A low carbon development initiative,” 2022. Ministerial Decree No. 168/MENLHK/PKTL/PLA.1/2022.
- [26] M. Abadi, P. Barham, J. Chen, *et al.*, “Tensorflow: A system for large-scale machine learning,” *USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, pp. 265–283, 2016.
- [27] IPCC, “Climate change and land: An ipcc special report on climate change, desertification, land degradation, sustainable land management, food security, and greenhouse gas fluxes in terrestrial ecosystems,” tech. rep., 2019.