

Segmentasi Deforestasi Multi-Temporal Menggunakan Sentinel-2 dan Label Hansen GFC

Proof-of-Concept untuk Pemantauan Otomatis 10 m

Farrel Khozy Affudin

Teknik Informatika, Universitas Darussalam Gontor
farrelaffudin@student.cs.unida.gontor.ac.id

Fatih Jawwad Al Mumtaz

Teknik Informatika, Universitas Darussalam Gontor
fatihalmumtaz76@student.cs.unida.gontor.ac.id

Amirul Al-Aziz

Teknik Industri Pertanian, Universitas Darussalam Gontor
amirulalaziz57@stdet.tip.unida.gontor.ac.id

Abstrak. Kami menyajikan pipeline proof-of-concept yang ringkas untuk segmentasi deforestasi otomatis pada resolusi 10 m di kawasan Hutan Lindung Kabupaten Boven Digoel dan Merauke, Papua Selatan, menggunakan pasangan komposit Sentinel-2 Level-2A dan label loss-year dari Hansen Global Forest Change (GFC). Tiga model dievaluasi: U-Net satu tanggal, U-Net multi-temporal bertumpuk, dan jaringan Siamese FC-Siam-diff. Model Siamese mencapai IoU uji global terbaik sebesar 0,137 dan skor F1 0,240, melampaui fusi bertumpuk (IoU 0,119) dan pembandingan satu tanggal (IoU 0,122). Meskipun metrik absolut masih dibatasi oleh ketimpangan kelas ekstrem (0,38 % piksel positif) dan ketidaksesuaian resolusi label 30 m–10 m, pipeline ini menunjukkan kelayakan operasional mulai dari ekspor citra satelit, pelatihan, inferensi, hingga visualisasi peringatan.

1 Pendahuluan

Indonesia memiliki sekitar 94 Mha hutan tropis dan kehilangan ratusan ribu hektare hutan setiap tahun [1]. Hutan lindung memerlukan pemantauan yang lebih rinci karena pembukaan kecil dapat terlewat oleh produk operasional beresolusi kasar. Hansen Global Forest Change menyediakan data kehilangan tutupan pohon tahunan pada resolusi 30 m, sedangkan pelaporan SIMONTANA Indonesia menggunakan unit pemetaan minimum 6,25 ha; keduanya belum memadai untuk peringatan dini sub-hektare. Citra Sentinel-2 pada resolusi 10 m memberikan dasar praktis untuk peringatan yang lebih rapat [2], tetapi label pelatihan pada resolusi sepadan mahal untuk diperoleh.

Studi ini menguji apakah label loss-year Hansen GFC dapat digunakan untuk mengawasi segmentasi Sentinel-2 dan apakah pemodelan perubahan multi-temporal eksplisit meningkatkan kinerja. Kami membandingkan segmentasi satu tanggal pasca-kejadian, penumpukan kanal pre/post secara naif, dan arsitektur Siamese dengan perbedaan fitur eksplisit. Pipeline lengkap mencakup ekspor Google Earth Engine [3], pemasangan chip, oversampling, pencarian hiperparameter, inferensi dengan augmentasi saat inferensi, dan visualisasi. Kode dan model tersedia di <https://github.com/FarrelKhozy/Deforest.id.git>.

2 Kajian Terkait dan Posisi Riset

Produk kehilangan hutan tahunan berbasis Landsat tetap penting untuk pemantauan global yang konsisten, tetapi resolusi spasial 30 m dan granularitas tahunan membatasi respons cepat terhadap gangguan kecil [1]. Sentinel-2 meningkatkan detail spasial menjadi 10 m dan menyediakan observasi revisit yang sering, sehingga cocok untuk peringatan lokal [2]. Namun, penerapan operasional masih memerlukan label yang skalabel, penanganan awan, dan penilaian akurasi yang kuat pada kondisi kejadian langka [4, 5].

Deep learning telah menjadi pendekatan standar untuk segmentasi citra padat karena encoder konvolusional dapat menggabungkan konteks spektral dan spasial melampaui threshold sederhana [6]. U-Net efektif untuk prediksi tingkat piksel karena skip connection mempertahankan detail spasial selama decoding [7]. Pada aplikasi hutan berbasis penginderaan jauh, varian U-Net telah digunakan untuk pemetaan tipe hutan dan deteksi gangguan [8], sementara U-Net berbasis attention juga telah dieksplorasi untuk deforestasi pada citra satelit [9]. Arsitektur change detection seperti FC-Siam-diff membandingkan fitur dari dua tanggal secara eksplisit, sehingga cocok untuk pemantauan deforestasi [10].

Riset ini diposisikan sebagai proof-of-concept yang berorientasi implementasi, bukan sebagai tolak ukur akurasi operasional final. Kontribusinya adalah mengukur apa yang terjadi ketika label Hansen GFC yang

mudah tersedia digunakan untuk mengawasi model Sentinel-2 10 m dan mengidentifikasi bagian pipeline yang menjadi hambatan: resolusi label, ketimpangan kelas, overfitting model, serta artefak awan atau komposit.

3 Metodologi

3.1 Data dan Label

Kami menggunakan citra Sentinel-2 Level-2A dari Google Earth Engine pada kawasan Hutan Lindung di Kabupaten Boven Digoel dan Merauke, Papua Selatan, Indonesia. Area studi mencakup tujuh area sampel pada rentang koordinat sekitar $138,13^{\circ}$ – $139,86^{\circ}$ BT dan $-5,85^{\circ}$ hingga $-4,46^{\circ}$ LS. Kanal yang digunakan adalah B2 (Blue), B3 (Green), B4 (Red), dan B8 (NIR), yang tersedia pada produk Sentinel-2 Level-2A surface reflectance [11]. Citra dipotong menjadi pasangan chip 64×64 pada resolusi 10 m, setara dengan 0,64 ha per chip. Mask acuan diturunkan dari Hansen Global Forest Change v1.11: piksel dengan loss-year sampai 2023 diberi label deforestasi, sedangkan piksel lain diberi label latar belakang [1, 12]. Piksel terkontaminasi awan diabaikan saat perhitungan loss.

Dataset berisi 40.484 pasangan chip dari 7 area sampel Papua Selatan: 23.135 chip latih, 5.822 chip validasi, dan 11.527 chip uji. Hanya 0,38 % dari seluruh piksel yang positif dan 74 % chip tidak mengandung deforestasi, sehingga terjadi ketimpangan kelas yang berat. Pengaturan ini sengaja mencerminkan peman-tauan operasional, di mana piksel kehilangan hutan merupakan kejadian langka dan penilaian akurasi harus memperhitungkan ketimpangan kelas [4].

3.2 Model dan Pelatihan

Tiga arsitektur dievaluasi. Pertama, **SimpleUNet** hanya menggunakan citra pasca-kejadian 2023 dengan lima kanal input. Kedua, **Stacked U-Net** menggabungkan input 2020 dan 2023 menjadi sepuluh kanal. Ketiga, **FC-Siam-diff** menggunakan encoder berbobot sama untuk dua tanggal dan menggabungkan fitur pasca-kejadian, fitur pra-kejadian, serta selisih fiturnya pada setiap skip connection decoder [10]. Segmentasi bergaya U-Net digunakan karena merupakan arsitektur standar untuk prediksi penginderaan jauh yang padat [7, 9], sedangkan Dice dan focal loss umum digunakan pada masalah deteksi yang tidak seimbang [13, 14].

Semua model multi-temporal menggunakan AdamW [15] (laju belajar 10^{-4} , weight decay 5×10^{-4}), cosine annealing, symmetric Dice loss, batch size 64 dengan gradient accumulation sehingga batch efektif menjadi 128, oversampling $10\times$ untuk chip positif, flip horizontal/vertikal acak, mixed precision, dan pe-motongan gradien 1,0. Sembilan konfigurasi hiperparameter diuji, termasuk encoder ResNet18/34 [16], loss Dice/Tversky/Focal/Lovász, augmentasi berat, dan pengaturan accumulation berbeda. Dice loss dengan accu-mulation dan oversampling $10\times$ untuk chip positif menjadi konfigurasi paling stabil.

Pelatihan memakai komponen deep learning standar agar sistem mudah direproduksi. AdamW digu-nakan untuk memisahkan weight decay dari update gradien [15], sementara momen adaptif gaya Adam tetap menjadi pembanding umum untuk optimisasi neural [17]. Evaluasi melaporkan IoU, precision, recall, F1 score, dan akurasi karena akurasi saja dapat menyesatkan ketika piksel latar belakang mendominasi [18]. Pada in-ferensi, augmentasi saat inferensi horizontal dan vertikal merata-ratakan beberapa prediksi untuk mengurangi sensitivitas terhadap orientasi chip tanpa mengubah model terlatih.

4 Hasil dan Diskusi

Tabel 1: Metrik global pada test set, dijumlahkan pada semua chip.

Metrik	Satu tanggal	Stacked	Siamese
IoU	0,122	0,119	0,137
Precision	0,198	0,154	0,196
Recall	0,239	0,344	0,311
F1	0,217	0,212	0,240
Accuracy	0,984	0,977	0,982

Model Siamese mencapai IoU dan skor F1 terbaik, menunjukkan bahwa perbedaan fitur eksplisit lebih berguna daripada penumpukan kanal secara naif. Model bertumpuk memiliki recall tertinggi tetapi menghasilkan lebih banyak positif palsu, sedangkan pembanding satu tanggal lebih presisi namun melewatkan lebih banyak kejadian. Rata-rata IoU per sampel jauh lebih rendah (0,012–0,015) karena sebagian besar chip tidak memiliki piksel positif; karena itu, metrik global lebih merepresentasikan kinerja tingkat piksel pada pemantauan kejadian langka.

Kurva validasi mencapai puncak pada epoch 4–6 lalu menurun, sementara training loss terus membaik. Pola ini menunjukkan overfitting akibat contoh positif yang terbatas dan konteks 64×64 yang kecil. Analisis kesalahan menunjukkan empat mode kegagalan utama: positif palsu dari perubahan pertanian, tanah terbuka, dan muka air; batas deforestasi yang terlalu halus; artefak bayangan awan residual [5]; serta noise label spasial/temporal akibat penggunaan label Hansen GFC tahunan 30 m untuk mengawasi komposit Sentinel-2 10 m. Kurva pelatihan disajikan pada Lampiran A.

Pencarian hiperparameter juga memberikan panduan praktis. Varian Tversky dan focal meningkatkan recall pada beberapa eksperimen, tetapi cenderung menurunkan precision atau membuat performa validasi awal kurang stabil. Augmentasi berat, termasuk rotasi dan jitter spektral, menurunkan hasil karena model bergantung pada hubungan kanal RGB, NIR, dan NDVI yang konsisten. Konfigurasi terbaik karena itu menggunakan augmentasi geometris sederhana, oversampling chip positif, dan pemilihan model awal pada puncak validasi. Hal ini mendukung kesimpulan bahwa, pada label lemah yang bising, kualitas data dan strategi sampling lebih penting daripada menambahkan augmentasi agresif.

5 Implementasi dan Keterbatasan

Pipeline berjalan pada satu GPU NVIDIA RTX 3060 di WSL2. Citra Sentinel-2 Level-2A diekspor sebagai GeoTIFF dari Google Earth Engine, dipotong menjadi chip NPZ, dipasangkan berdasarkan indeks spasial, disimpan di RAM, dan dilatih dengan PyTorch presisi campuran. Pelatihan membutuhkan kurang dari 30 menit untuk 30 epoch; inferensi penuh pada 11.390 chip uji dengan augmentasi saat inferensi horizontal dan vertikal membutuhkan sekitar 12 menit. Ini menunjukkan bahwa alur kerja dapat direproduksi pada perangkat keras konsumen, bukan hanya infrastruktur cloud khusus.

Keterbatasan utama adalah kualitas label. Data loss-year Hansen GFC berasal dari Landsat 30 m, sehingga setiap piksel label mencakup sembilan piksel Sentinel-2 dan waktu kehilangan tahunan belum tentu cocok dengan komposit 2020/2023. Pembukaan kecil yang terlihat pada 10 m juga dapat hilang dari label Hansen GFC. Selain itu, ketimpangan kelas ekstrem, konteks chip terbatas, artefak komposit, dan pergeseran distribusi antara wilayah latih dan uji membatasi generalisasi. Keterbatasan ini menjelaskan metrik yang masih moderat dan menunjukkan bahwa label yang lebih baik kemungkinan akan meningkatkan performa lebih besar daripada perubahan arsitektur saja.

Keterbatasan kedua adalah interpretabilitas bagi pengguna operasional. Petugas kehutanan membutuhkan peringatan yang koheren secara spasial, bukan piksel terisolasi. Karena itu, penerapan berikutnya perlu mengagregasi komponen terhubung, menghapus kluster positif palsu yang sangat kecil, dan menambahkan skor ketidakpastian pada setiap peringatan. Proof-of-concept saat ini sudah menghasilkan visualisasi per chip, tetapi sistem operasional memerlukan poligon georeferensi, pemeringkatan peringatan, dan umpan balik validasi lapangan.


6 Kesimpulan

Proof-of-concept ini menunjukkan bahwa segmentasi multi-temporal Sentinel-2 dengan label turunan Hansen GFC layak digunakan untuk pemantauan deforestasi otomatis 10 m. FC-Siam-diff mencapai hasil terbaik (IoU 0,137, skor F1 0,240), mengonfirmasi bahwa representasi perubahan eksplisit mengungguli stacking naif dan inferensi satu tanggal. Pekerjaan lanjutan perlu berfokus pada label berkualitas lebih tinggi dari anotasi manual atau citra resolusi tinggi, chip yang lebih besar dengan mekanisme attention, fusi SAR Sentinel-1, dan pascapemrosesan komponen terhubung untuk peringatan operasional.

Daftar Pustaka

- [1] M. C. Hansen, P. V. Potapov, R. Moore, *et al.*, “High-resolution global maps of 21st-century forest cover change,” *Science*, vol. 342, no. 6160, pp. 850–853, 2013.
- [2] M. Drusch, U. Del Bello, S. Carlier, *et al.*, “Sentinel-2: ESA’s optical high-resolution mission for GMES operational services,” *Remote Sensing of Environment*, vol. 120, pp. 25–36, 2012.
- [3] N. Gorelick, M. Hancher, M. Dixon, *et al.*, “Google earth engine: Planetary-scale geospatial analysis for everyone,” *Remote Sensing of Environment*, vol. 202, pp. 18–27, 2017.
- [4] R. G. Congalton, “A review of assessing the accuracy of classifications of remotely sensed data,” *Remote Sensing of Environment*, vol. 37, no. 1, pp. 35–46, 1991.
- [5] Z. Zhu and C. E. Woodcock, “Object-based cloud and cloud shadow detection in landsat imagery,” *Remote Sensing of Environment*, vol. 118, pp. 83–94, 2012.
- [6] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [7] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, vol. 9351, pp. 234–241, 2015.
- [8] F. H. Wagner, A. Sanchez, Y. Tarabalka, R. G. Lotte, M. P. Ferreira, M. P. M. Aidar, E. Gloor, O. L. Phillips, and L. E. O. C. Aragao, “Using the U-Net convolutional network to map forest types and disturbance in the atlantic rainforest with very high resolution images,” *Remote Sensing in Ecology and Conservation*, vol. 5, no. 4, pp. 360–375, 2019.
- [9] D. John and C. Zhang, “An attention-based u-net for detecting deforestation within satellite sensor imagery,” *International Journal of Applied Earth Observation and Geoinformation*, vol. 107, p. 102685, 2022.
- [10] R. C. Daudt, B. Le Saux, and A. Boulch, “Fully convolutional siamese networks for change detection,” in *2018 25th IEEE International Conference on Image Processing (ICIP)*, pp. 4063–4067, 2018.
- [11] Google Earth Engine Data Catalog, “Sentinel-2 msi: Multispectral instrument, level-2a harmonized surface reflectance,” 2024. Dataset ID: COPERNICUS/S2_SR_HARMONIZED; bands B2, B3, B4, and B8 used in this study.
- [12] Google Earth Engine Data Catalog, “Hansen global forest change v1.11 (2000–2023),” 2023. Dataset ID: UMD/hansen/global_forest_change_2023_v1.11.
- [13] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” *International Conference on 3D Vision (3DV)*, pp. 565–571, 2016.
- [14] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, “Focal loss for dense object detection,” in *2017 IEEE International Conference on Computer Vision (ICCV)*, pp. 2999–3007, 2017.
- [15] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019. Published conference paper.
- [16] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- [17] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” *International Conference on Learning Representations (ICLR)*, 2015.
- [18] D. M. W. Powers, “Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation,” *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.

A Kurva Pelatihan



Gambar 1: Kurva pelatihan untuk konfigurasi Siamese terbaik: loss, IoU, precision/recall/F1, dan laju belajar selama 30 epoch.